O RAG está morto? A ascensão da engenharia de contexto e das camadas semânticas para IA agente.

Introdução

A Geração Aumentada por Recuperação (RAG), na sigla em inglês pode ter sido renovada como uma "técnica de IA", mas a verdade é que ela sempre foi muito mais do que isso. Desde o início, a RAG se apresentou como uma arquitetura complementar que complementava recursos técnicos de texto quando faziam sentido, mas nunca foi concebida como um paradigma de agente.

Este artigo explora como essa evolução está se consolidando e o que isso significa para os líderes de dados e IA que constroem sistemas capazes de raciocinar de forma responsável.

Você está disposto a responder essas perguntas difíceis?

Como os grafos de conhecimento melhoram a RAG?

Eles fornecem estruturas e significados aos dados corporativos, conectando entidades e relacionamentos em vários documentos e bancos de dados para tornar recuperações mais precisas e explicável tanto para humanos quanto para agentes de IA.

Como as ontologias melhoram ainda mais os modelos de aprendizagem de linguagem (LLMs) e sistemas inteligentes?

As camadas semânticas padronizam as definições de dados e as políticas de governança para que modelos possam interpretar, raciocinar e recuperar informações com mais exatidão. Isso ajuda, bem como sobre ferramentas de IA, memória e outros agentes.

Como a RAG está sendo usada em IA agente?

A incorporação de informações está se tornando uma etapa em um ciclo de raciocínio mais amplo, onde sistemas recuperam dados sob demanda no contexto e podem se aprender com eles, comprimem, isolam e sintetizam dinamicamente o contexto em diferentes dados e ferramentas.

O RAG (Retrieving Aggregators) ganhou destaque após o lançamento do ChatGPT e a popularização do conceito em linha para o preenchimento de contexto não é possível simplesmente copiar todos os dados para uma interface de chat. As equipes adotaram o RAG e suas variações para fornecer aos modelos o que eles precisam saber, seja por meio de pesquisas, dados contexto intensivos no momento da consulta. A popularidade da RAG logo expôs suas limitações: janelas de contexto sobrecarregadas, custos crescentes e modelos que leem muito pouco, ou nenhuma, pouco se recuperam em meio a tal volume de texto. Novas técnicas, como o processamento de contexto estruturado, começaram a resolver esses limites, mas o RAG não foi projetado para sobreviver ao novo mundo dos agentes.

Agentes de IA precisam de memória, ferramentas e contexto que ajustem independentes, e recuperação de informações o que variações são simples uma ferramenta no arsenal de um agente. Pesquisadores e arquitetos, e desafiaremos os sistemas de contexto. Conforme as complexidades dos fluxos de trabalho e a quantidade de informações possíveis para construir um contexto preciso aumentam, a engenharia de contexto se torna um campo de pesquisa e design próprio. Em contexto, RAG 2.0 é o nome que alguns usam para a evolução da recuperação de informações rica engenharia de contexto exigirá o gerenciamento de memória, ferramentas e recursos estruturados. Mais pesquisas e ferramentas, memória e recursos estruturados. Agentes avançados e incorporação de informações que ajustam e sintetizam dinamicamente o contexto em diferentes dados e ferramentas.

A ascensão da RAG

O que é RAG?

RAG, ou Geração Aumentada por Recuperação é uma técnica para recuperar informações relevantes e complementares e um estímulo enviado a um modelo de aprendizado de máquina (LLM) para gerar uma resposta ancorada.

Logo após o ChatGPT se popularizar em novembro de 2022, os usuários perceberam que os modelos de linguagem precisavam de um ponto para acessar informações específicas que não estavam pontos dados. Para superar essa lacuna, as equipes pretendem desenvolver maneiras de fornecer a seus modelos informações no momento da inferência. Muitas delas acabaram por desenvolver conexões com grafos de conhecimento para recuperação (RAG). O termo surgiu em um artigo de pesquisa de 2020 de Facebook que propunha modelos ORT treinados para gerar e otimizar conexões entre recuperação e geração.

Parceiramos como LangChain e LlamaIndex ajudaram os desenvolvedores a construir esses pipelines de recuperação. O LangChain foi lançado quase simultaneamente ao ChatGPT como uma maneira de conectar LLMs a APIs e bancos de dados. Pouco depois, o LlamaIndex surgiu para oferecer ferramentas de ingestão e recuperação de dados. O LlamaIndex também se tornou uma maneira de criar grafos de conhecimento a partir dados não-estruturados, tornando-os mais úteis e complementar. No final de 2023, Juan Sequeda, Dean Allemang e Bryan Jacobs, da data.world, publicaram um artigo demonstrando como grafos de conhecimento podem melhorar os resultados e a explicabilidade do LLM. Em julho de 2024, a Microsoft lançou seu pacote GraphRag de código aberto, que trouxe as capacidades que eles haviam desenvolvido para grafos locais acrescentar a um público maior ampliando as desenvolvedores e criando ferramentas para criar e manipular grafos de conhecimento.

O surgimento do GraphRAG ressaltou o interesse entre grafos de conhecimento, de forma semelhante ao interesse gerado pelo artigo do Facebook sobre RAG cinco anos antes. O ano de 2024 demonstra rapidamente por contínuo estruturado e recuperação explícitamente ao contínuo.

Entre **2023 e 2025** , o mercado respondeu:

- **23 de janeiro de 2023 - A Digital Science adquiriu a metaphactory**, criadora de plataformas de gráficos de conhecimento, projetada para ajudar a tornar mais fácil a criação de grafos de conhecimento e a avaliação e democratização do conhecimento.
- **Em fevereiro de 2023 - A Progress adquiriu a MarkLogic e lançou a MarkLogic em fevereiro de 2023.** MarkLogic é um banco de dados NoSQL multimodal, com destaque especial no gerenciamento de dados RDF e vetoriais, e oferece suporte a consultas e armazenamento de gráficos.
- **18 de julho de 2024 - A Semantic Web Company adquiriu a Ontotext.** Ontotext é um banco de dados de gráficos de RDF, bem conhecido por seu mecanismo de gráficos focado semântica e um público maior ampliado de desenvolvedores e criadores de knowledge graph, que oferecem recursos de gerenciamento.

O surgimento do GraphRAG recebeu o interesse em gráficos de conhecimento, de forma semelhante ao interesse gerado pelo artigo do Facebook sobre RAG cinco anos antes. O ano de 2024 demonstra rapidamente por contínuo estruturado e recuperação explícitamente ao contínuo.

Entre **2023 e 2025** , o mercado respondeu:

- **23 de janeiro de 2023 - A Digital Science adquiriu a metaphactory**, criadora de plataformas de gráficos de conhecimento, projetada para ajudar a tornar mais fácil a criação de grafos de conhecimento e a avaliação e democratização do conhecimento.
- **Em fevereiro de 2023 - A Progress adquiriu a MarkLogic e lançou a MarkLogic em fevereiro de 2023.** MarkLogic é um banco de dados NoSQL multimodal, com destaque especial no gerenciamento de dados RDF e vetoriais, e oferece suporte a consultas e armazenamento de gráficos.
- **18 de julho de 2024 - A Semantic Web Company adquiriu a Ontotext.** Ontotext é um banco de dados de gráficos de RDF, bem conhecido por seu mecanismo de gráficos focado semântica e um público maior de desenvolvedores e criadores de knowledge graph, que oferecem recursos de gerenciamento.

Essas são apenas os exemplos relacionados a grafos de conhecimento e tecnologias semânticas. Em todo o mundo, os gastos com gerenciamento de dados não-estruturados e camadas semânticas de forma mais ampla, encontraremos mais negócios, principalmente a partir de 2024. Os analistas do setor estimam que o gasto anual ultrapasse US$ 1 bilhão.

Essa mudança marcaram uma transição clara: os grafos de conhecimento deixaram de ser apenas ferramentas de gerenciamento de metadados e passaram a ser vistos como parte da semântica de IA, aprimorando os dados sobre cargas como sistemas especializados. O GraphRAG ressaltou a ideia de grafos de conhecimento, ampliando tanto o alcance quanto o reconhecimento, no julgamento e na explicabilidade.

Após 50 anos de IA simbólica, os dados sob uma definição. Embora seja provável que uma demonstração do RAG em minutos, e muitas pessoas o fizeram, escalar e aplicativos em uma empresa trazem um novo conjunto. Segundo o Gartner, 60% dos projetos de IA de 2024 não serão provavelmente concluídos por falta de dados prontos para IA. Isso significa que, mesmo com um número crescente de ferramentas de IA, muitas delas não conseguirem ultrapassar os limites corporativos, e um problema muito diferente", diremos Bryan Jacobs, CTO da data.world e um dos autores do artigo sobre o uso de grafos de conhecimento para LLMs.

Um dos problemas com a escalabilidade de um aplicativo RAG é o volume de dados necessário no momento da recuperação. "Não faz o problema que as pessoas enfrentam é muito semelhante ao que enfrentamos com o Big Data. Muitas empresas acham que podem jogar 100.000 ou 1.000.000 de documentos", afirma Kjetil Sturkl . Mas a medida que os Modelos de Linguagem (LLMs) ficam mais inteligentes, a janela de contexto que eles conseguem processar está crescendo rapidamente. Isso torna o problema original que, a RAG foi criada para resolver, o tal tesouro a quando se RAG ainda é necessário ou até. Continuamos a ver.

As despesas arbitrariamente mais informações no prompt de contexto, você não arriscou apenas atrasar o processamento e aumentar os custos de inferência, mas também. Os Achievements podem enfrentar as respostas dos LLMs Governing Learning Models, dados que a janela de contexto ainda é finita e que, mesmo dentro dessa janela, os modelos podem ter dificuldade em processar muitas informações ao mesmo tempo. Pesquisas recentes sobre "perdido no meio" ressaltam que os transformadores contaminam o processo de atenção, o que significa que, à medida que a janela de contexto se expande, a capacidade o modelo com um grande volume de informações, levando à "confusão de contexto" no fornecimento de respostas. Embora a janela de contexto tenha se expandido significativamente, a precisão do modelo tende a diminuir além de um certo ponto. Manter o contexto relevante e focado continua sendo um desafio crítico para a IA empresarial. Um artigo recente da Chroma, que demonstrou "deterioração de contexto" A publicação de Chroma descreveu como o desempenho dos LLMs muda significativamente à medida que a janela de contexto.

Para lidar com o problema de sobrecarga" ou modelos ou fornecer informações incoerentes ou irrelevantes, muitas equipes recorreram a técnicas como **selecionar** (escolher quais informações são relevantes), **comprimir** (reduzir, dispensar de apresentar o texto, decida o que manter e o que descartar), e **isolar** (dividir grandes fluxos de trabalho em componentes menores). Frameworks como Kevin, Voyage de Harvey, Jina Reranker e RGE Reranker. No entanto, uma redescoberta não é a técnica mais avançada. Em agosto de 2025, a equipe por trás do RAG (Retrieval-Augmented Gisting) foi incorporada aos agentes – algo cada vez mais comum como engenharia de contexto.

O que é Engenharia de Contexto?

Se entre a última de preparar o prompt de contexto com a informação exata o cada passo do raciocínio do agente, chamamos isso de "Engenharia de Contexto".

Quem me concentrar na engenharia de contexto foi por dois motivos: os criadores dos Semantic Layers (RAG) Pi, Kwindla Kramer e Daniel Lenharo. Conversamos com eles sobre o que é usar a terra engenharia de contexto e o um terreno muito mais popular, com base nas características do Google. A engenharia de prompt é o que acontece quando um humano está envolvido na evolução da engenharia de prompts. A engenharia de prompts consiste em criar um prompt específico e preciso para um modelo de linguagem. Isso pode ser feito por um humano ou por um sistema de IA treinado para otimizar os prompts.

O RAG (Random Approach - Respostas, Ações e Respostas) ganhou destaque em 2023, uma era ainda na fetha do tempo de IA (Inteligência Artificial). Desde então, tudo se tornou muito mais rápido. Em 2025, a ideia de usar um prompt longo para obter uma resposta e a resposta seria feita por um humano. Como agentes, precisamos comprimir como tais. Quando o RAG foi criado, o problema era que os modelos de linguagem não conseguiam **compreender o contexto** do que estavam lendo. Os modelos precisavam de informações de uma tarefa para ação, assim como os humanos. Frequentemente, os agentes precisam de informações de uma tarefa para ação. Isso significa que a engenharia de contexto se torna cada vez mais relevante. Um exemplo disso é a ideia de "contexto de contexto" no Google Agent Development Kit (ADK). Isso envolve gerenciamento de contexto em diferentes sessões e agentes, ou seja, ajuda o modelo de linguagem a "lembrar de coisas" sobre o que eles possam. como descreve Anthropic , "explorar diferentes partes do problema e encontrar a melhor". Em vez de se preocupar em fornecer o contexto mais específico, o ideal seria que o modelo se aprendesse por conta de maneira mais eficiente.

Os agentes precisam usar a memória quando necessário ou recorrer a ferramentas para obtenção de mais informações. Isso também **melhorar** também a velocidade e a eficiência. Uma dessas ferramentas pode ser uma recuperação baseada em vetores, ou seja, o tradicional RAG. Agentes podem usar o RAG, bem como outras ferramentas, como chamadas de APIs, ferramentas de agente. Como disse Mark Brooker, da AWS: "Eu acredito que veremos algumas arquiteturas muito interessantes surgindo em torno de modelos e agentes que podem usar ferramentas para obter mais informações sob demanda, e ideia aqui é que o modelo de aprendizado de máquina (LLM) não é suficiente para gerar inteligência."

A engenharia de contexto precisa de uma camada semântica.

O que é uma camada semântica?

Uma camada semântica é uma forma de fornecer metadados e todos os dados de uma forma que seja legível tanto para humanos quanto para máquinas, para que possam se compatibilizar e entender o que se quer dizer ao consultar dados de forma consistente.

Recentemente, observamos uma principal dos parceiros de especialistas em dados relacionados a criação de uma camada semântica para IA empresarial. Os dados estão em toda parte. Os dados estão em toda parte. Os dados estão em toda parte